

Projeto de Pesquisa — Anexo à Declaração de Responsabilidade

Documento formal do projeto para submissão junto à Declaração de Responsabilidade prevista no parágrafo único do Art. 8º da Resolução nº 200/2021/CONSELHO UNIVERSITÁRIO da Universidade Federal de São Paulo.

1. Identificação

Título do projeto	Mitigação de Viés Racial em Classificação Facial via Condicionamento por Tom de Pele e
Mestrando	Marcello Ozzetti
Orientador / Pesquisador Responsável	Marcos Quiles
Programa	Mestrado em Ciência da Computação
Instituição	Universidade Federal de São Paulo — Instituto de Ciência e Tecnologia (Unifesp / ICT)
Linha de pesquisa	Visão Computacional e Equidade Algorítmica
Período previsto	julho de 2026 a outubro de 2026 (qualificação)

2. Resumo

Sistemas modernos de reconhecimento facial apresentam disparidade demográfica significativa entre grupos raciais, mesmo quando treinados sobre datasets explicitamente balanceados. No estado da arte atual, o modelo FaceScanPaliGemma sobre o dataset público FairFace atinge F1 de 90 % para faces classificadas como Black, mas apenas 60 % para faces classificadas como Latinx — uma diferença de trinta pontos percentuais que persiste através de múltiplos métodos e arquiteturas. Esta dissertação propõe um pipeline de classificação racial que incorpora tom de pele (escala Monk Skin Tone, dez classes) como sinal auxiliar condicionante via mecanismo arquitetural FiLM (Feature-wise Linear Modulation), e avalia sua capacidade de reduzir essa disparidade sem sacrificar acurácia agregada. **A pesquisa é inteiramente computacional, conduzida sobre datasets públicos secundários, sem coleta primária, intervenção ou qualquer forma de envolvimento direto ou indireto de seres humanos.**

3. Justificativa e problema de pesquisa

O reconhecimento facial deixou de ser tecnologia laboratorial e passou a integrar a infraestrutura social — desbloqueio de dispositivos, autenticação bancária, identidade digital, controle de fronteiras e identificação policial. Em escala industrial, o National Institute of Standards and Technology auditou em 2019 cento e oitenta e nove algoritmos de reconhecimento facial sobre dezoito milhões de imagens, documentando diferenciais de dez a cem vezes na taxa de falso positivo entre grupos raciais.

Apesar de mais de uma década de pesquisa em equidade algorítmica, a disparidade persiste. O baseline ResNet-34 sobre FairFace, o FaceScanPaliGemma via VLM, e mesmo modelos

com balanceamento explícito de dados continuam apresentando F1 aproximadamente 60 % para a categoria Latinx / Hispanic. Trabalhos recentes sugerem que essa disparidade não é apenas artefato algorítmico, mas reflete heterogeneidade fenotípica intra-categorial que a rotulagem racial monolítica do FairFace não captura adequadamente.

O problema de pesquisa desta dissertação é, portanto: **condicionar arquiteturalmente um classificador racial pelo tom de pele reduz a disparidade demográfica sem sacrificar acurácia agregada, e permite decompor o erro em componentes fenotípico e algorítmico?**

4. Objetivos

4.1 Objetivo geral

Desenvolver e avaliar um pipeline de classificação racial em imagens faciais que incorpora tom de pele (escala Monk Skin Tone) como sinal auxiliar condicionante via mecanismo arquitetural FiLM, com o propósito de mitigar viés racial demonstrável no estado da arte atual — particularmente a disparidade severa entre classes raciais bem representadas e classes sub-representadas documentada em modelos como FaceScanPaliGemma sobre o dataset FairFace.

4.2 Objetivos específicos

1. **Auditoria fenotípica do FairFace** — quantificar a distribuição cruzada MST × classes raciais sobre o FairFace via SkinToneNet pré-treinado, entregando a primeira matriz pública dessa distribuição.
2. **Avaliação metodológica de classificadores MST** — comparar SkinToneNet, Casual Conversations baseline e alternativas disponíveis, com *sensitivity analysis* a dois ou três classificadores alternativos para mitigar risco de propagação de viés.
3. **Race classifier com conditioning arquitetural** — treinar ConvNeXt-T *fine-tuned* em FairFace, com camadas FiLM por estágio recebendo o vetor MST como contexto.
4. **Comparação sistemática contra baselines de mitigação** — avaliar o pipeline contra seis baselines (ResNet-34, ConvNeXt-T puro, FSCL+, Group DRO, FineFACE, Adversarial debiasing) via triangulação de métricas (DR + *worst-class* F1 + EO_h/EOD).
5. **Fair transferência para face recognition downstream** — aplicar o backbone fair em *face recognition* em RFW ou BFW, com controle explícito de *pixel information* como *confounder*.
6. **Síntese decompositiva** — combinar resultados dos objetivos 1 e 5 para quantificar componente fenotípico (irreduzível) versus componente algorítmico (mitigável) do erro Latinx.

5. Metodologia

5.1 Natureza da pesquisa

A pesquisa é **puramente computacional**. Consiste em treinamento e avaliação de modelos de aprendizado profundo sobre datasets de imagens faciais já existentes e publicamente disponíveis; análise estatística de métricas de desempenho estratificadas por grupo demográfico; comparação sistemática entre configurações arquiteturais; e síntese analítica dos resultados.

5.2 Datasets utilizados — todos secundários e públicos

Dataset	Origem	Licença	Uso na pesquisa
FairFace	Kärkkäinen & Joo (2021), UCL	CC BY 4.0 (uso acadêmico)	Dataset principal — 108.501 imagens balanceadas em
RFW	Wang et al. (2019), BUPT	Research-only (mediante autorização)	Avaliação de fair transferência downstream
BFW	Robinson et al. (2020), RIT	CC BY 4.0	Avaliação alternativa de fair transferência
BUPT-Balancedface	Wang, Zhang, Deng (2022)	Research-only	Sensitivity analysis do backbone
STW	Pereira et al. (2026)	Research-only	Base de treino do SkinToneNet (uso apenas como mod

Todas as imagens desses datasets foram coletadas, anotadas e disponibilizadas por seus autores originais anteriormente ao início desta pesquisa. Este projeto não coleta, não anota e não distribui qualquer imagem original.

5.3 Pipeline metodológico em seis etapas

Etapa 1 — Classificador MST: uso do SkinToneNet pré-treinado como insumo, mediante validação de concordância interna em subset estratificado.

Etapa 2 — Auditoria FairFace: aplicação do SkinToneNet sobre o FairFace validation set e construção da matriz pública MST × raça.

Etapa 3 — Race classifier com conditioning: treinamento do ConvNeXt-T em FairFace train, com camadas FiLM recebendo o vetor MST como contexto arquitetural.

Etapa 4 — Comparação contra baselines: avaliação do pipeline contra seis baselines de mitigação, com triangulação métrica.

Etapa 5 — Fair transferência: aplicação do backbone fair em face recognition downstream (RFW ou BFW).

Etapa 6 — Síntese decompositiva: quantificação do componente fenotípico versus algorítmico do erro Latinx.

5.4 Rigor experimental

Todos os experimentos serão conduzidos com múltiplas sementes aleatórias (mínimo três: 42, 1, 2), comparação pareada entre configurações, intervalos de confiança via *bootstrap* e reporte estratificado por raça e por interseção raça × gênero. As métricas seguirão triangulação (DR + *worst-class* F1 + EO_h/EOD) para endereçar o Teorema da Impossibilidade de Kleinberg.

5.5 Validação humana — modalidade interna

Para o Objetivo Específico 1, será conduzida validação de concordância entre o SkinToneNet e anotação manual em subset estratificado de aproximadamente duzentas a trezentas imagens do FairFace. **Esta validação será realizada exclusivamente pela equipe**

acadêmica do projeto — Mestrando e Orientador (e Coorientador, se designado). **Não** haverá contratação de anotadores externos, não haverá uso de plataformas de crowdsourcing, e não haverá coleta de qualquer dado pessoal de indivíduos externos à equipe.

6. Aspectos éticos — enquadramento no Art. 8º da Resolução 200/2021

Este projeto **não envolve, direta ou indiretamente, seres humanos como sujeitos de pesquisa**, conforme a definição estabelecida pela Resolução nº 200/2021 do Conselho Universitário da Universidade Federal de São Paulo e pelas Resoluções nº 466/2012 e nº 510/2016 do Conselho Nacional de Saúde. Justifica-se:

6.1 Ausência de coleta primária

O projeto **não coleta**, em nenhuma etapa, imagens de rostos, dados biométricos, dados demográficos, opiniões, comportamento ou qualquer outra informação de seres humanos identificáveis ou identificados. Todas as imagens utilizadas são secundárias, provenientes de datasets construídos e disponibilizados publicamente por terceiros anteriormente ao início desta pesquisa.

6.2 Ausência de intervenção

O projeto **não realiza intervenção** de qualquer natureza sobre seres humanos — não há entrevistas, questionários, experimentos, testes psicológicos, exames físicos, uso de dispositivos, alteração de ambiente ou qualquer procedimento que produza efeito sobre pessoas físicas.

6.3 Ausência de envolvimento indireto via crowdsourcing

Diferentemente de projetos que empregam plataformas de crowdsourcing (Amazon Mechanical Turk, Prolific, Toloka, entre outras) para anotação de dados, este projeto **não contrata anotadores externos**. A validação manual prevista no Objetivo Específico 1 será conduzida exclusivamente por membros da equipe acadêmica do projeto, enquadrando-se como atividade de pesquisa científica interna e não como recrutamento de participantes.

6.4 Ausência de identificação de sujeitos

As análises produzidas nesta pesquisa referem-se a **grupos demográficos agregados** (categorias raciais, tons de pele) e não a indivíduos identificáveis. Nenhum resultado publicado permitirá identificar pessoas específicas presentes nos datasets utilizados.

6.5 Ausência de uso de animais vertebrados vivos

O projeto **não utiliza animais vertebrados vivos** de qualquer natureza, não se enquadrando na competência da Comissão de Ética no Uso de Animais (CEUA).

6.6 Enquadramento formal

Pelo exposto, este projeto se enquadra no **Art. 8º da Resolução nº 200/2021/CONSU** — “Os projetos de pesquisa que não envolvem seres humanos, direta e indiretamente, nem animais vertebrados vivos, estão dispensados de cadastro” — e é objeto da **Declaração de Responsabilidade** prevista no parágrafo único do referido artigo, assinada pelo estudante, pelo orientador e pelo chefe do Departamento ao qual o orientador está vinculado.

7. Cronograma

Marco	Data	Descrição
Primeira revisão da qualificação ao orientador	15/jul/2026	Documento completo em LaTeX / Overleaf
Pedido formal de qualificação ao Programa	30/jul/2026	Prazo regimental do PPG-CC / ICT

Marco	Data	Descrição
Defesa da qualificação	outubro/2026	Sujeita à prorrogação já solicitada de dois meses
Experimentos completos e escrita da dissertação	nov/2026 – mai/2027	—
Defesa da dissertação	2º semestre/2027	—

8. Referências principais

Datasets e benchmarks

Kärkkäinen & Joo (2021). FairFace: Face Attribute Dataset. WACV.

Wang et al. (2019). Racial Faces in the Wild — RFW. ICCV.

Robinson et al. (2020). Face Recognition: Too Bias, or Not Too Bias? CVPRW.

Hazirbas et al. (2021). Casual Conversations. CVPRW.

Fundamentação teórica em fairness

Buolamwini & Gebru (2018). Gender Shades. FAT*.

Hardt et al. (2016). Equality of Opportunity in Supervised Learning. NeurIPS.

Kleinberg et al. (2017). Inherent Trade-Offs in the Fair Determination of Risk Scores. ITCS.

Madras et al. (2018). Learning Adversarially Fair and Transferable Representations. ICML.

Skin tone e conditioning arquitetural

Schumann et al. (2023). Consensus and Subjectivity of Skin Tone Annotation — MST-E. CVPR.

Pereira et al. (2026). Large-Scale Dataset and Benchmark for Skin Tone Classification in the Wild — SkinToneNet. arXiv:2603.02475.

Perez et al. (2018). FiLM: Visual Reasoning with a General Conditioning Layer. AAAI.

Refutação e diálogo crítico

Pangelinan et al. (2023). Analyzing Bias in Race Classification. FAccT.

AlDahoul et al. (2024). FaceScanPaliGemma. arXiv.

Diversidade fenotípica intra-Latinx

Telles (2014). Pigmentocracies: Ethnicity, Race, and Color in Latin America. UNC Press.

Bryc et al. (2015). The Genetic Ancestry of African Americans, Latinos, and European Americans across the United States. AJHG.

Pew Research (2017). Hispanic Identity Fades Across Generations.

Bibliografia consolidada de 104 referências disponível no repositório do projeto (arquivo referencias.bib).

9. Local de execução

Toda a pesquisa será conduzida em **ambiente computacional próprio** do mestrando e em infraestrutura de computação disponibilizada pela Unifesp / ICT ou por serviços de computação em nuvem contratados individualmente (Google Colab Pro, AWS educacional ou equivalente). **Não há uso de laboratórios institucionais que envolvam seres humanos ou animais.**

10. Declaração final

Declaro, para os devidos fins, que o projeto de pesquisa aqui descrito não envolve, direta ou indiretamente, seres humanos como sujeitos de pesquisa, nem faz uso de animais vertebrados

vivos, enquadrando-se no Art. 8º da Resolução nº 200/2021 do Conselho Universitário da Universidade Federal de São Paulo. Comprometo-me a submeter novo protocolo ao Comitê de Ética em Pesquisa da Unifesp caso, no curso da pesquisa, sobrevenha qualquer alteração de escopo que envolva seres humanos ou animais.

São Paulo, 08 de julho de 2026.

Marcello Ozzetti — Mestrando

Prof. Dr. Marcos Quiles — Orientador / Pesquisador Responsável